

Московский государственный технический университет им. Н.Э. Баумана
Факультет «Информатика и системы управления»
Кафедра «Системы обработки информации и управления»



Домашнее задание по курсу
«Методы машинного обучения»

Реферат на тему:

**«Проблемы классификация видов деревьев по данным LiDAR с
помощью модели глубокого обучения»**

ИСПОЛНИТЕЛЬ:

Нурлыева Дана Джалилевна
Группа ИУ5-21М

_____ 2021 г.

Аннотация

Инвентаризация деревьев-важная задача для экологии, расчета поглощения углекислого газа и обустройства города. Но разные типы деревьев имеют свои особенности, и проблема их автоматической классификации является актуальной. В настоящее время для решения этой задачи используются различные датчики, но наиболее часто используется лидар. Применяются различные методы классификации, включая глубокое обучение. Одной из современных моделей глубокого обучения для данных облака точек является PointNet. Поэтому авторы этой работы применили его для классификации древесных пород. В России есть свой собственный специфический набор древесных пород, и авторы собрали для исследования набор данных, содержащий типичные для этой области виды деревьев, и провели его маркировку. Результаты показали хорошие возможности PointNet для классификации видов деревьев, но выявили проблему недостаточности данных для высокой точности обучения и трудности с ручной маркировкой экземпляров на основе данных облака точек. В статье даны рекомендации по преодолению этих проблем.

Вступление

Одной из наиболее обсуждаемых и актуальных проблем на данный момент является проблема экологии. Существует огромное количество различных факторов, влияющих на состояние природы, и одним из них является углерод. Это совокупность всех выбросов парниковых газов, которые прямо или косвенно сопровождают любую деятельность человека или организации с точки зрения углекислого газа. Чтобы ограничить глобальное потепление по сравнению с доиндустриальным уровнем, было принято Парижское соглашение. Это юридически обязательный международный договор об изменении климата, вступивший в силу 4 ноября 2016 года[1].

В соответствии с этим соглашением странам рекомендуется принимать меры по осуществлению и поддержке мероприятий, связанных с сохранением лесов, устойчивым лесопользованием и увеличением запасов углерода в лесах в развивающихся странах. [1] Именно поэтому возникает необходимость следить за ситуацией с лесными насаждениями и за тем, сколько углерода будет поглощено той или иной частью лесной насаждения. Точная характеристика лесных видов и их пространственное распределение имеют решающее значение для устойчивого лесопользования, а также для экологии и охраны окружающей среды [2, 3]. В случае городских районов классификация видов деревьев привлекает все большее внимание для моделирования шума, а также экологического анализа, поскольку деревья играют решающую роль в городских экосистемах для поддержания качества окружающей среды, эстетической красоты городского ландшафта [4].

За последние 35 лет число исследований, посвященных классификации древесных пород, постоянно росло, что хорошо подтверждается общей тенденцией к увеличению публикационной активности [5]. Между периодами 2005-2010 и 2010-2015 годов наблюдается почти экспоненциальный рост, обусловленный увеличением доступности гиперспектральных и бортовых лидарных данных. Оба источника данных часто применяются в контексте инвентаризации лесов, причем древесные породы являются одним из наиболее популярных целевых вариантов, помимо общего объема растущего запаса и биомассы [5]. Лесные насаждения в Российской Федерации имеют свои особенности и требуют исследований по видам данной территории [6].

LiDAR (Light Detection and Ranging) - это технология дистанционного зондирования, которая использует свет в виде импульсного лазера для измерения переменных расстояний до объекта. Излучая инфракрасные лазерные импульсы, а также регистрируя местоположение и ориентацию объекта в пространстве, формируется плотное трехмерное облако точек, отражающее окружающее пространство. Растущая доступность лидара вызвала большой интерес у менеджеров природных ресурсов, поскольку LiDAR можно использовать для измерения характеристик деревьев [7]. В то же время точность классификации отдельных деревьев остается низкой [2].

Различные типы лидаров уже используются для классификации видов деревьев. В течение последнего десятилетия исследователи изучали возможность использования данных бортового лидара для классификации типов древостоев или отдельных видов [2]. Более поздний мобильный LiDAR привлек большое внимание к обнаружению и моделированию городской растительности, поскольку он создаёт данные с гораздо более высокой плотностью точек и более полным охватом данных, чем бортовая лидарная система, и с более высокой эффективностью, чем наземная лидарная система [4].

Для классификации деревьев применяются различные алгоритмы. Сначала наиболее широко используемые методы классификации включали контролируемые классификаторы максимального правдоподобия и неконтролируемую кластеризацию (K-means, ISODATA). Позже в качестве альтернативы другим классификаторам появились непараметрические классификаторы на основе дерева решений и нейронные сети. В некоторых недавних исследованиях, использующих смешанные наборы входных переменных, предпочтение отдается использованию непараметрических методов машинного обучения, таких как RF или SVM [5].

Классификация лидарных данных с помощью PointNet

Облако точек-это самый простой способ представления объекта в виде набора отдельных точек в геометрической системе координат X, Y и Z. Облака точек создаются путем сканирования объектов или их структуры с помощью 3D-датчиков, таких как лидар. В процессе глубокого обучения для 3D-облака точек обычно решаются две задачи: классификация и сегментация.

PointNet-это модель, обрабатывающая неструктурированные данные облака точек с использованием сверточной нейронной сети. Архитектура PointNet [9] показана на рис. 1. Классификационная сеть состоит из двух сетей преобразования, каждая из которых имеет общий многослойный перцептрон (MLP) с размерами выходного слоя (64, 64) и (64, 128, 1024) и максимальным объединением.

Существуют различные модели распознавания облаков лидарных точек, но наиболее эффективными являются модели глубокого обучения. SEGCloud сочетает в себе методы классического машинного обучения и глубокие архитектуры, то есть эта модель использует воксельные сетки и необработанные 3D-точки, полученные с помощью трилинейной интерполяции [8]. PointNet работает непосредственно с облаком точек [9]. Эта сеть показала впечатляющие результаты в распознавании 3D-объектов внутри помещений и семантической сегментации [10]. PointNet++ [11], который является вариантом PointNet, был успешно применен для идентификации деревьев в облаках точек [12]. Поэтому было решено использовать PointNet для классификации видов деревьев по облаку точек.

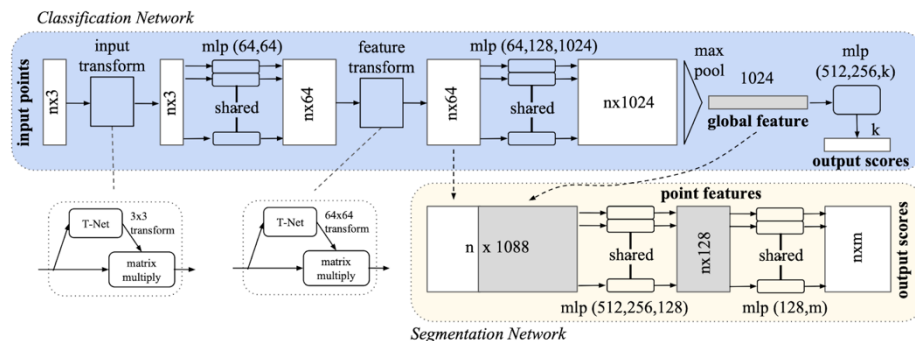


Рис. 1. Архитектура PointNet

Этот метод берет рассеянные и неупорядоченные данные облака точек, состоящие из N точек, и обрабатывает их отдельно с помощью N! перестановок при условии, что модель инвариантна к этим изменениям. Одна точка не рассматривается изолированно. Напротив, точка взаимодействует со своими ближайшими соседями, и они часто несут информацию, полезную для классификации. Таким образом, PointNet использует две симметричные функции (1), которые делают модель устойчивой к преобразованиям, причем выходные данные этих функций по-прежнему совпадают с входными:

$$f(\{x_1, \dots, x_n\}) = g(h(x_1), \dots, h(x_n)) \quad (1)$$

где $g(x)$ - максимальный объединяющий слой, а $h(x)$ - многослойный перцептрон.

MLP-это преобразования объектов, которые независимо отображают каждую из N точек из одного измерения в другое. Последняя трансформационная сеть также имеет два полностью связанных слоя с выходными размерами (512, 256, k), где k-количество классов. Для предсказания класса данного облака точек модель в ее конечном слое имеет функцию активации softmax, которая часто используется для задач многоклассовой

классификации. Для минимизации частоты ошибок модели используется оптимизатор Adam, который сочетает в себе преимущества оптимизаторов RMSProp и AdaGrad.

Сбор данных

Для идентификации деревьев было проведено обследование территории в лесу с использованием лидарного устройства GeoSLAM ZEB-HORIZON. С диапазоном измерения до 100 м он идеально подходит для съемки открытых пространств. Он сканирует 300 000 точек в секунду с точностью 1-3 см. Для предварительной обработки лидарных данных использовалось программное обеспечение GeoSLAM Hub + Draw, которое преобразует исходные данные 3D-сканирования в формат pcd.

Измерения проводились в центральном регионе Европейской России. В результате этого опроса были получены изображения деревьев в облаке точек. Отдельные деревья были вручную выбраны из полных изображений местности и помещены в отдельные файлы с помощью программного обеспечения 3D Forest. После всех преобразований был получен 261 образ дерева.

После сбора файлов необходимо было пометить данные, определить тип каждого дерева. Для этого полученный набор данных просматривался вручную, и каждому дереву присваивалась своя метка. Всего было идентифицировано 10 видов, и для всех видов были выбраны соответствующие названия видов на латыни. Классы Castanea и Salix, содержащие недостаточное количество примеров, были исключены из набора данных. Количество экземпляров для остальных классов представлено в таблице 1. В процессе маркировки для каждого вида дерева были определены его уникальные критерии: объем ствола, крона дерева, направление роста ветвей и т.д.

Таблица 1. Количество экземпляров в наборе данных каждого класса

Tree	Aspen	Poplar	Spruce	Birch	Linden	Maple	Pine	Oak
Species	Populus tremula	Populus alba	Picea abies	Betula pendula	Tilia cordata	Acer platanoides	Pinus sylvestris	Quercus robur
Quantity	17	33	48	35	8	26	66	20

Данные были собраны в зимний сезон, что позволило снимать деревья без листьев, делая крону более информативной [2]. Однако маркировка является довольно трудоемким процессом, поскольку часто не хватало экспертных знаний, чтобы однозначно определить тип дерева [2]. В виде облаков точек очень трудно определить, к какому виду относится то или иное дерево.

Для более полной картины необходимо иметь изображение самого захваченного дерева. Поэтому было решено провести маркировку отдельно друг от друга тремя участниками, а затем сформировать окончательную выборку из тех деревьев, где вид однозначно идентифицирован. Поскольку невозможно было точно классифицировать вручную все изображения деревьев, в итоговую выборку было включено только 253 дерева (рис. 2).



Рис. 2. Примеры деревьев слева направо: береза, ель, тополь

Эксперимент и результаты

Данные были преобразованы в формат сетки и далее в формат 2048 точек для модели. Набор данных был разделен на обучающие и тестовые выборки в соотношении 80% к 20%. Чтобы улучшить качество обучения, примеры были перемешаны и перемешаны по нормальному распределению.

За основу была взята реализация модели точечной сети с сайта keras [13], которая показала точность 73% в наборе данных ModelNet10. Обучение проводится в Google Colab с использованием графического процессора. Оптимизатор был изменен на ЦУР со скоростью обучения 0,001 вместо Adam. В процессе обучения было выполнено 50 эпох, и 32% точности классификации было достигнуто по тестовым данным после 5-й эпохи (рис. 3). Точность на тестовой и обучающей выборках имеет одинаковые значения, что указывает на то, что модель не переобучена.

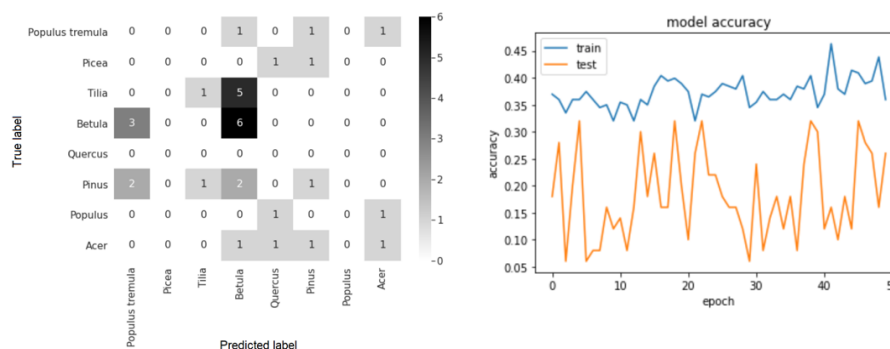


Fig. 1. Confusion matrix and model accuracy by epochs

Точность оказалась ниже 77,5% [2] и 86% [4]. Это связано с тем, что количество копий в наборе данных меньше, чем в этих работах. В работе [2] также было 10 классов, но количество копий в каждом было 5000, то есть на два порядка больше, чем в нашем исследовании. В исследовании [4] количество примеров в каждом классе варьировалось от 300 до 400. Это на порядок больше, но авторы изучали только 4 класса. Качество разметки набора данных также влияет на классификацию.

В результирующей матрице ошибок (рис. 3) видно, что результирующая модель лучше всего распознает класс Betula из тестового набора данных. Матрица путаницы показывает, что большинство ошибок равномерно распределены в матрице между классами. Но существует сильная корреляция между классами Betula и Picea, модель ошибочно распознает ель как березу. Однако трудно сделать окончательный вывод из-за дисбаланса классов: у Пинуса 66, в то время как у Тилии всего 6 примеров.

Заключение

Результаты, полученные в ходе исследования, показали хорошие возможности модели точечной сети для классификации древесных пород даже на небольшом объеме данных. В то же время были выявлены проблемы с ручной маркировкой облаков точек деревьев. Объем данных, собранных для обучения и тестирования, также был недостаточным. В будущих исследованиях планируется значительно увеличить количество примеров для каждого класса. Для повышения качества разметки планируется использовать комбинированные данные с камер и лидаров.

Список использованных источников

1. UNFCCC website, Paris Agreement (2015), https://unfccc.int/sites/default/files/english_paris_agreement.pdf, last accessed 2021/05/18.
2. Li J., Hu B., Noland T.L.: Classification of tree species based on structural features derived from high density LiDAR data. Agricultural and Forest Meteorology 171–172, 104–114 (2013).

3. Chumachenko S.I., Korotkov V.N., Palenova M.M., Politov D.V.: Simulation modelling of long-term stand dynamics at different scenarios of forest management for coniferous - broad-leaved forests. *Ecological Modelling* 170(2), 345-361 (2003).
4. Guan H., Ji Z., Yu Y., Li J.: Deep learning-based tree classification using mobile LiDAR data. *Remote Sensing Letters* 6(11), 864-873 (2015).
5. Fassnacht F.E., Latifi H., Sterenczak K., Modzelewska A., Lefsky M., Waser L.T., Straub C., Ghosh A.: Review of studies on tree species classification from remotely sensed data. *Remote Sensing of Environment* 186, 65-87 (2016).
6. Eroshenkova D. A., Terekhov V.I., Khusnetdinov D.R., Chumachenko S.I.: Automated determination of forest-vegetation characteristics with the use of a neural network of deep learning. In: *International Conference on Neuroinformatics*, pp. 295-302. Springer (2019).
7. Hudak A.T., Evans J.S., Smith A.: LiDAR utility for natural resource managers. *Remote Sensing* 1(4), 934–951 (2009).
8. Tchapmi L.P., Choy C.B., Armeni I., Gwak J.Y., Savarese S.: SEGCloud: Semantic Segmentation of 3D Point Clouds (2017), <https://arxiv.org/pdf/1710.07563.pdf>, last accessed 2021/05/18.
9. Qi C.R., Su H., Mo K., Guibas L.J.: PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation (2017), <https://arxiv.org/pdf/1612.00593.pdf>, last accessed 2021/05/18.
10. Fei J., Peng K., Heidenreich P., Bieder F., Stiller C.: PillarSegNet: Pillar-based Semantic Grid Map Estimation using Sparse LiDAR Data (2021), <https://arxiv.org/pdf/2105.04169.pdf>, last accessed 2021/05/18.
11. Qi C.R., Yi L., Su H., Guibas L.J.: PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space (2017), <https://arxiv.org/pdf/1706.02413v1.pdf>, last accessed 2021/05/18.
12. Gupta A., Byrne J., Moloney D., Watson S., Yin H.: Tree Annotations in LiDAR Data Using Point Densities and Convolutional Neural Networks (2020), <https://arxiv.org/pdf/2006.05560.pdf>, last accessed 2021/05/18.
13. Keras website, <https://keras.io/examples/vision/pointnet>, last accessed 2021/05/18.